ДОКУМЕНТАЦИЯ

Техническая документация проекта

Прогнозирование энергопотребления и стоимости электричества

---

1. Назначение и описание проекта

1.1 Целевая функция

Проект реализует систему прогнозирования двух ключевых показателей:

1. **Энергопотребление (кВт·ч)** — объём электроэнергии, потребляемой за день
2. **Стоимость электроэнергии (руб/кВт·ч)** — цена за единицу электроэнергии
3. **Итоговые расходы (рубли)** — произведение энергопотребления и цены

Система использует **линейную регрессию** (LinearRegression из scikit-learn) для поиска зависимостей между метеорологическими, календарными факторами и целевыми показателями.

1.2 Входные данные

Проект работает с синтетическими данными, включающими:

- **Временной период**: 100 дней (с 1 января 2021 года)
- **Температура воздуха**: от -10 до +10 °C (целые значения)
- **Энергопотребление**: от 200 до 500 кВт·ч (целые значения)
- **Цена электроэнергии**: от 4.5 до 6.5 руб/кВт·ч (с шумом ±0.1)

1.3 Целевая аудитория

- Студенты, изучающие основы машинного обучения
- Специалисты по анализу данных
- Разработчики систем прогнозирования
- Энергетические компании (для демонстрационных целей)

---

2. Архитектура решения

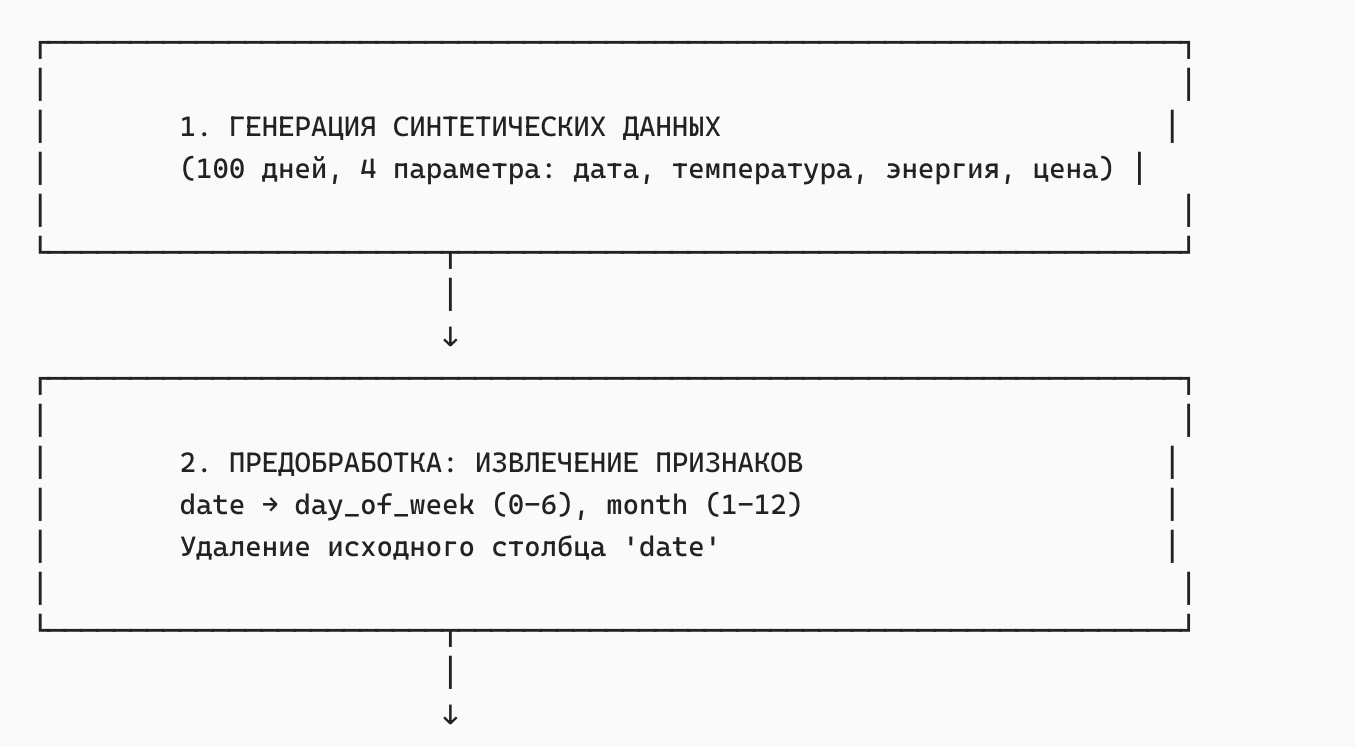
2.1 Стек технологий

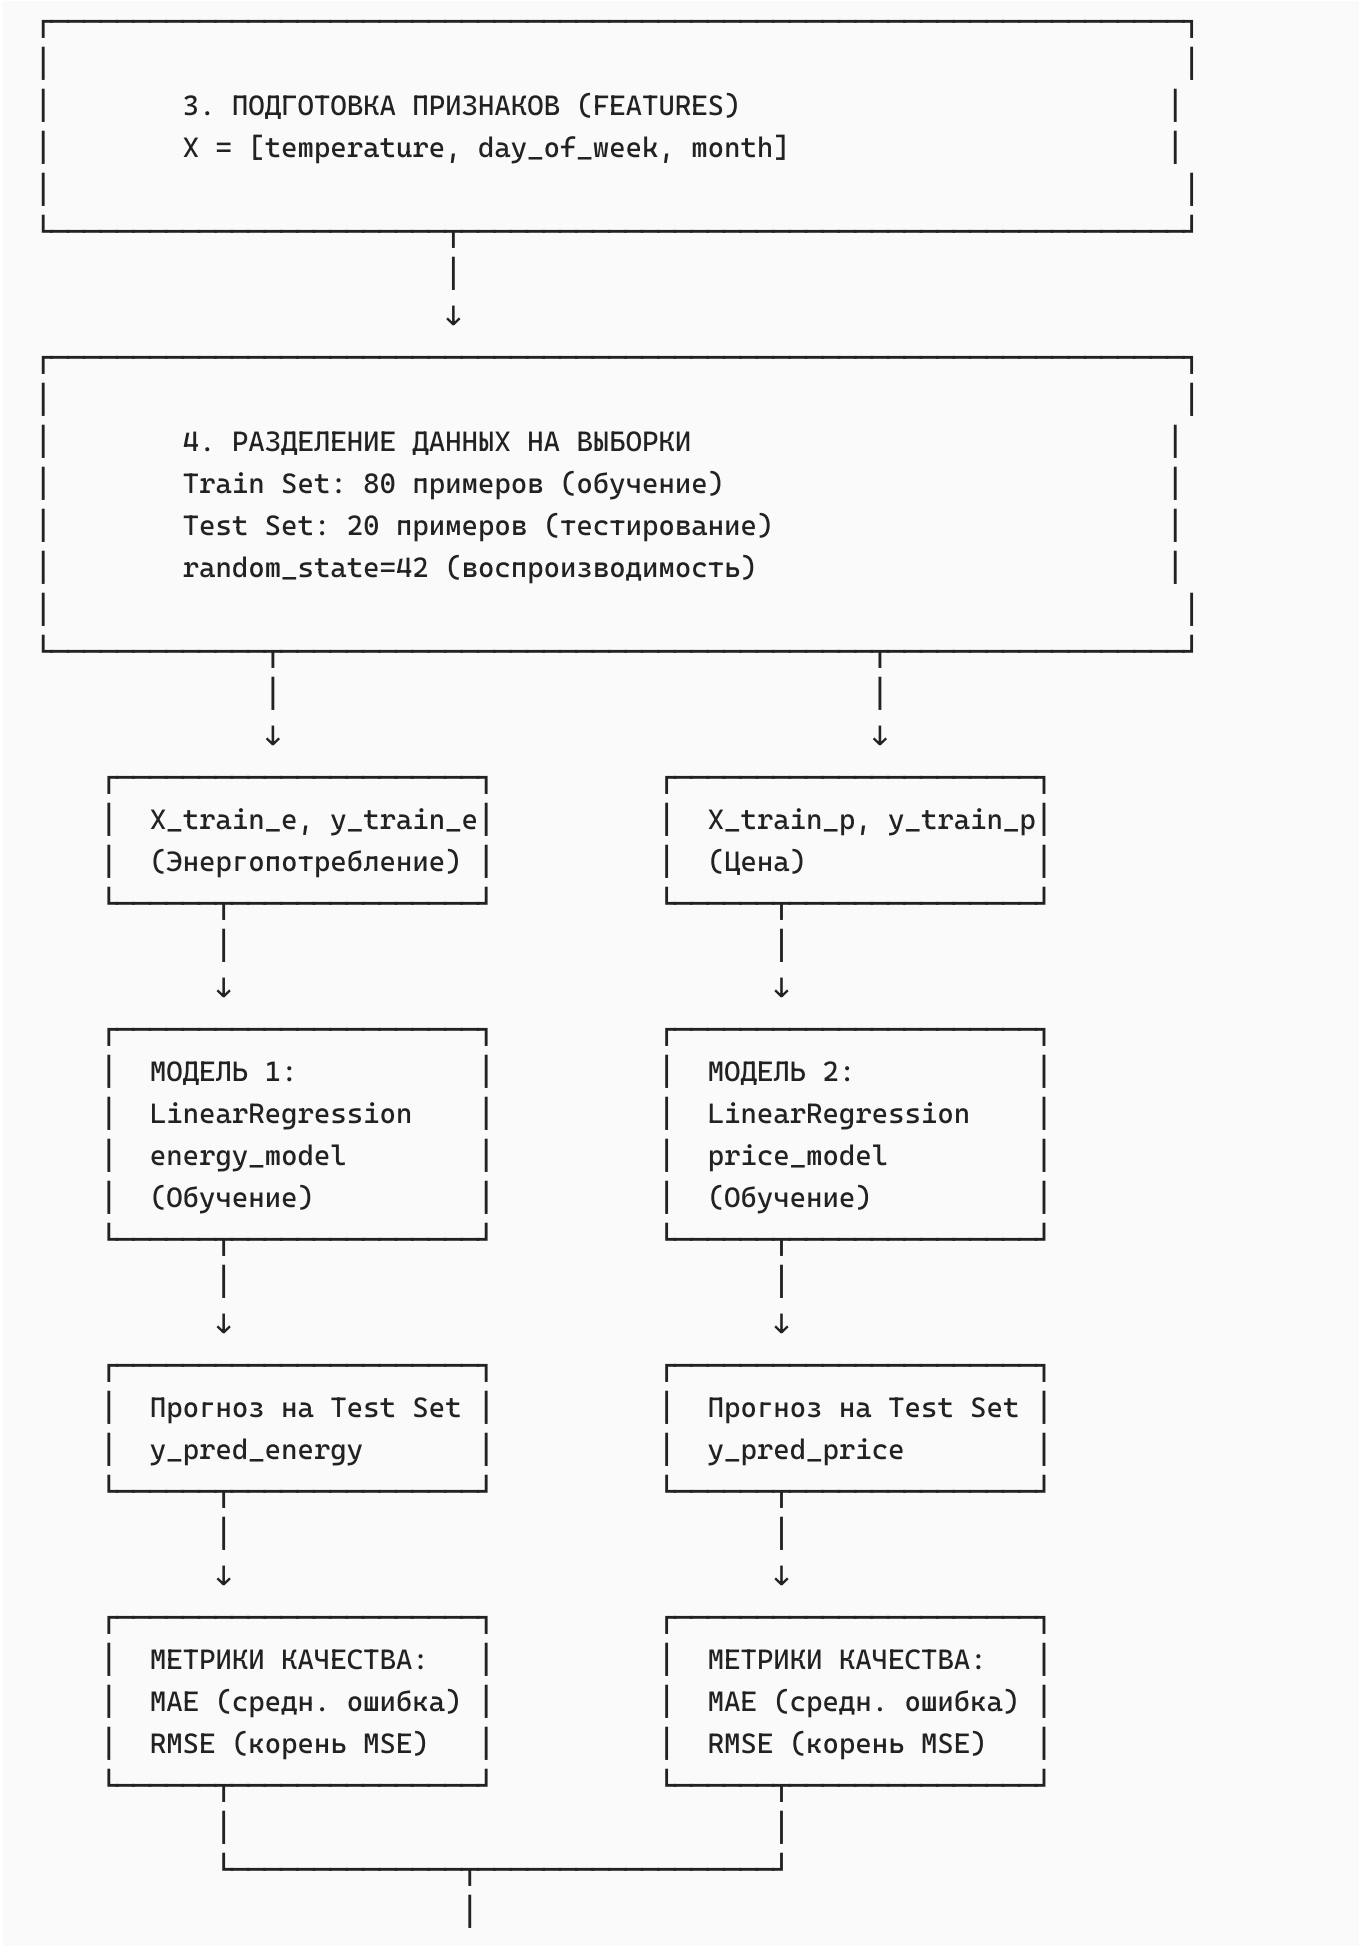
Компонент	Библиотека	Версия	Назначение
Обработка данных	pandas	1.3+	Работа с табличными данными (DataFrame)
Числовые вычисления	numpy	1.21+	Генерация массивов, математические операции
Машинное обучение	scikit-learn	0.24+	Линейная регрессия, разделение данных, метрики качества
Визуализация	matplotlib	3.4+	Построение графиков и диаграмм рассеяния
Статистическое отображение	seaborn	0.11+	Расширенные графики, гистограммы с KDE (сглаженное отображение распределения)

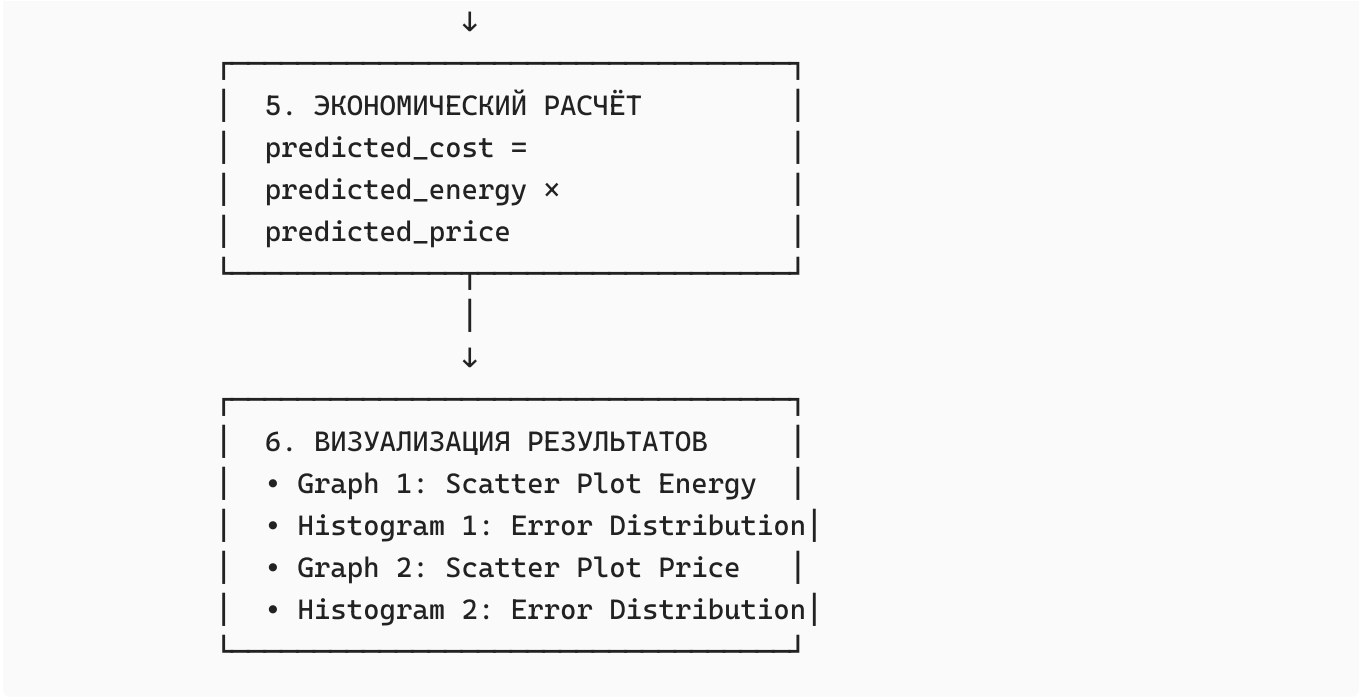
2.2 Архитектурная схема

Подробная архитектурная схема представлена на отдельной странице (см. раздел 2.3).

2.3 Полная архитектурная схема проекта




3. ПОДГОТОВКА ПРИЗНАКОВ (FEATURES)
X = [temperature, day_of_week, month]
4. РАЗДЕЛЕНИЕ ДАННЫХ НА ВЫБОРКИ
Train Set: 80 примеров (обучение)
Test Set: 20 примеров (тестирование)
random_state=42 (воспроизводимость)
X_train_e, y_train_e
(Энергопотребление)
X_train_p, y_train_p
(Цена)
МОДЕЛЬ 1:
LinearRegression
energy_model
(Обучение)
МОДЕЛЬ 2:
LinearRegression
price_model
(Обучение)
Прогноз на Test Set
y_pred_energy
Прогноз на Test Set
y_pred_price
МЕТРИКИ КАЧЕСТВА:
MAE (средн. ошибка)
RMSE (корень MSE)
МЕТРИКИ КАЧЕСТВА:
MAE (средн. ошибка)
RMSE (корень MSE)



---

3. Детальное описание кода

3.1 Блок 1: Импорт библиотек и генерация данных

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error
import matplotlib.pyplot as plt
import seaborn as sns
```

Назначение: Подключение всех необходимых библиотек.

Генерация синтетического датасета:

```
data = {
    'date': pd.date_range(start='2021-01-01', periods=100, freq='D'),
    'temperature': np.random.randint(-10, 10, size=100),
    'energy_consumption': np.random.randint(200, 500, size=100),
}
df = pd.DataFrame(data)
df['price_per_kwh'] = np.linspace(4.5, 6.5, len(df)) + np.random.normal(0,
0.1, len(df))
```

Описание параметров:

- `pd.date_range()` — создаёт временной ряд из 100 последовательных дней
- `np.random.randint()` — генерирует целые числа в заданном диапазоне
- `np.linspace()` — равномерное распределение чисел от 4.5 до 6.5
- `np.random.normal()` — добавляет гауссовский шум для реалистичности

3.2 Блок 2: Предобработка данных (Feature Engineering)

```
df['day_of_week'] = df['date'].dt.dayofweek    # 0=понедельник, 6=воскресенье
df['month'] = df['date'].dt.month               # 1-12
df = df.drop('date', axis=1)                    # Удаляем исходную дату
```

Признаки для моделей:

- **day_of_week** — день недели (числовой признак 0-6)
- **month** — номер месяца (числовой признак 1-12)
- **temperature** — температура в градусах Цельсия

Почему удаляется дата: Дата — не числовой признак. Её разложили на компоненты (день недели, месяц), которые модель может использовать.

3.3 Блок 3: Модель 1 — Прогнозирование энергопотребления

```
X_energy = df[['temperature', 'day_of_week', 'month']]
y_energy = df['energy_consumption']

X_train_e, X_test_e, y_train_e, y_test_e = train_test_split(
    X_energy, y_energy, test_size=0.2, random_state=42
)

energy_model = LinearRegression()
energy_model.fit(X_train_e, y_train_e)
y_pred_energy = energy_model.predict(X_test_e)

mae_energy = mean_absolute_error(y_test_e, y_pred_energy)
rmse_energy = np.sqrt(mean_squared_error(y_test_e, y_pred_energy))
```

Параметры разделения:

- `test_size=0.2` — 20 примеров на тест, 80 на обучение
- `random_state=42` — фиксированное значение для воспроизводимости

Метрики качества:

- **MAE** (Mean Absolute Error) — средняя абсолютная ошибка в кВт·ч
- **RMSE** (Root Mean Squared Error) — корень из среднеквадратичной ошибки (штрафует большие ошибки)

3.4 Блок 4: Визуализация Модели 1

График 1: Реальные vs Прогнозируемые значения

```
plt.figure(figsize=(10, 6))
plt.scatter(y_test_e, y_pred_energy, label='Предсказанные значения')
plt.plot([y_test_e.min(), y_test_e.max()],
         [y_test_e.min(), y_test_e.max()],
         lw=2, label='Линия идеального предсказания')
plt.title('Реальные vs Предсказанные значения энергопотребления')
plt.xlabel('Реальное энергопотребление (кВт·ч)')
plt.ylabel('Предсказанное энергопотребление (кВт·ч)')
plt.legend()
plt.show()
```

Интерпретация:

- Если все точки лежат на диагональной линии → модель идеально предсказывает
- Если точки рассеяны вокруг линии → модель хорошая, но с небольшими ошибками
- Если облако точек далеко от линии → модель слабая

Гистограмма 1: Распределение ошибок

```
errors_energy = y_test_e - y_pred_energy
sns.histplot(errors_energy, kde=True)
plt.title('Распределение ошибок предсказания энергопотребления')
```

Назначение параметра `kde=True`: Добавляет плавную сглаживающую линию (KDE — Kernel Density Estimation) поверх столбиков гистограммы. KDE показывает общее распределение данных, сглаживая скачки столбцов.

Интерпретация:

- Если гистограмма сосредоточена около нуля → ошибки маленькие
- Если широко разбросана → ошибки большие
- Если смещена вправо → модель недооценивает; влево → переоценивает

- Если линия KDE имеет один чёткий пик → ошибки сосредоточены в одной области (хорошо)
- Если линия KDE имеет несколько пиков → есть разные типы ошибок (нужна оптимизация)

3.5 Блок 5: Модель 2 — Прогнозирование цены

Аналогично Модели 1, но для целевой переменной `price_per_kwh`:

```
X_price = df[['temperature', 'day_of_week', 'month']]
y_price = df['price_per_kwh']

X_train_p, X_test_p, y_train_p, y_test_p = train_test_split(
    X_price, y_price, test_size=0.2, random_state=42
)

price_model = LinearRegression()
price_model.fit(X_train_p, y_train_p)
y_pred_price = price_model.predict(X_test_p)

mae_price = mean_absolute_error(y_test_p, y_pred_price)
rmse_price = np.sqrt(mean_squared_error(y_test_p, y_pred_price))
```

Различие от Модели 1: Только целевая переменная (`y_price` вместо `y_energy`).

3.6 Блок 6: Экономический расчёт

```
df['predicted_energy'] = energy_model.predict(X_energy)
df['predicted_price'] = price_model.predict(X_price)
df['predicted_cost'] = df['predicted_energy'] * df['predicted_price']
```

Назначение: Вычисление прогнозируемых дневных расходов на электричество.

---

4. Математическая основа

4.1 Линейная регрессия

Модель ищет линейную зависимость:

$$\hat{y} = w_0 + w_1 \cdot \text{temperature} + w_2 \cdot \text{day_of_week} + w_3 \cdot \text{month}$$

где:

- $\hat{y}$ — предсказанное значение (энергия или цена)
- w_0, w_1, w_2, w_3 — коэффициенты, найденные при обучении
- temperature, day_of_week, month — входные признаки

4.2 Метрики качества

MAE (Mean Absolute Error) — Средняя абсолютная ошибка

Математическое определение:

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Простое объяснение:

- Берутся все ошибки: реальное значение минус предсказанное (`y_i - ŷ_i`)
- Берется абсолютное значение (модуль) каждой ошибки (чтобы -10 и +10 были одинаково «плохи»)
- Считается среднее значение всех ошибок

Пример:
Если MAE энергопотребления = 45 кВт·ч, значит модель ошибается в среднем на 45 кВт·ч. Это может быть недооценка на 45 или переоценка на 45.

Преимущества:

- Интуитивно понятна: результат в тех же единицах, что и целевая переменная
- Прямолинейная интерпретация: среднее отклонение прогноза

Недостатки:

- Не штрафует за большие ошибки. Одна ошибка на 1000 и сто ошибок на 10 дают одинаковый MAE

RMSE (Root Mean Squared Error) — Среднеквадратичная ошибка

Математическое определение:

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Простое объяснение:

- Берутся все ошибки: (`y_i - ŷ_i`)
- Каждая ошибка возводится в квадрат (большие ошибки становятся ещё больше)

- Считается среднее значение квадратов ошибок
- Берется квадратный корень (чтобы вернуться к исходным единицам)

Пример:
Если RMSE энергопотребления = 65 кВт·ч, это означает, что в среднем модель ошибается примерно на 65 кВт·ч. Но RMSE выше, чем MAE, потому что есть большие ошибки.

Преимущества:

- Сильно штрафует за большие ошибки (возведение в квадрат)
- Полезна, когда большие ошибки недопустимы (например, в критичных системах)

Недостатки:

- Результат зависит от наличия выбросов (одна огромная ошибка сильно влияет на RMSE)
- Менее интуитивна для интерпретации

Сравнение MAE и RMSE

Сценарий	MAE	RMSE	Интерпретация
Ошибки: 1, 2, 3	2.0	2.16	Примерно одинаковые, нет выбросов
Ошибки: 1, 2, 100	34.3	57.9	RMSE намного выше из-за большой ошибки
Ошибки: 5, 5, 5	5.0	5.0	Идентичны, когда все ошибки одинаковые

Когда использовать:

- **MAE**: Когда нужна простая интерпретация, ошибки примерно одинакового размера
- **RMSE**: Когда большие ошибки недопустимы и нужно их минимизировать

Практическое применение в проекте

```
# Расчёт MAE и RMSE для энергопотребления
mae_energy = mean_absolute_error(y_test_e, y_pred_energy)
rmse_energy = np.sqrt(mean_squared_error(y_test_e, y_pred_energy))

print(f"MAE энергопотребления: {mae_energy:.2f} кВт·ч")
print(f"RMSE энергопотребления: {rmse_energy:.2f} кВт·ч")

# Интерпретация:
# Если MAE = 42 кВт·ч, RMSE = 58 кВт·ч
```

```
# → Есть несколько больших ошибок (RMSE > MAE)
# → В среднем ошибка около 42 кВт·ч
```

---

5. Использование проекта

5.1 Запуск программы

```
python 11.py
```

Вывод в консоль:

```
Прогноз энергопотребления:
MAE: XX.XX
RMSE: XX.XX

Прогноз цены электроэнергии:
MAE: XX.XX
RMSE: XX.XX

Экономический прогноз (первые 5 строк):
   predicted_energy  predicted_price  predicted_cost
0            XXX.XX            X.XX           XXXX.XX
...
```

5.2 Интерпретация результатов

Метрика	Хорошее значение	Плохое значение
MAE энергии	< 50 кВт·ч	> 150 кВт·ч
RMSE энергии	< 60 кВт·ч	> 200 кВт·ч
MAE цены	< 0.3 руб	> 1.0 руб
RMSE цены	< 0.4 руб	> 1.5 руб

Пороги условные — зависят от масштаба данных.

---

6. Возможные улучшения

6.1 Краткосрочные улучшения

1. **Добавить больше признаков**:
   - Праздничные дни (boolean flag)
   - Влажность воздуха
   - Скорость ветра
   - Солнечная активность
2. **Использовать нелинейные модели**:
   - RandomForestRegressor (ансамбль деревьев)
   - GradientBoostingRegressor (более точный, медленнее)
   - SVR (метод опорных векторов)
3. **Кросс-валидация**:

```
from sklearn.model_selection import cross_val_score
scores = cross_val_score(energy_model, X_energy, y_energy, cv=5)
```

6.2 Среднесрочные улучшения

- Работа с реальными данными (Open Data платформы)
- Обработка пропущенных значений (NaN)
- Нормализация признаков (StandardScaler, MinMaxScaler)
- Отбор наиболее значимых признаков (feature selection)

6.3 Долгосрочные улучшения

- Развёртывание в production (Flask/FastAPI API)
- Использование временных рядов (ARIMA, Prophet)
- Глубокое обучение (LSTM, Transformer)
- Интеграция с системой мониторинга и алертов

---

7. Возможные проблемы и решения

Проблема	Причина	Решение
MAE/RMSE слишком большие	Недостаточно признаков	Добавить больше входных данных
Модель переобучена	Малый датасет	Увеличить объём данных, использовать регуляризацию

Проблема	Причина	Решение
Модель недообучена	Сложность задачи	Попробовать нелинейные модели
Значительная корреляция между признаками	Мультиколлинеарность	Удалить коррелирующие признаки, использовать PCA

---

8. Зависимости и установка

8.1 Требования

```
pandas>=1.3.0
numpy>=1.21.0
scikit-learn>=0.24.0
matplotlib>=3.4.0
seaborn>=0.11.0
```

8.2 Установка

```
pip install pandas numpy scikit-learn matplotlib seaborn
```

---

9. Практические примеры использования

9.1 Пример 1: Прогноз для конкретного дня

```
# Предположим, день недели=2 (среда), месяц=6 (июнь), температура=15°C
new_data = np.array([[15, 2, 6]])
predicted_energy = energy_model.predict(new_data)[0]
predicted_price = price_model.predict(new_data)[0]
predicted_cost = predicted_energy * predicted_price

print(f"Прогноз на среду, июнь, 15°C:")
print(f"Энергопотребление: {predicted_energy:.2f} кВт·ч")
print(f"Цена: {predicted_price:.2f} руб/кВт·ч")
print(f"Итоговые расходы: {predicted_cost:.2f} руб")
```

9.2 Пример 2: Анализ влияния температуры

```
temperatures = np.arange(-10, 15, 1)
predictions = []

for temp in temperatures:
    X_sample = np.array([[temp, 3, 6]])  # Фиксируем день и месяц
    pred = energy_model.predict(X_sample)[0]
    predictions.append(pred)

plt.plot(temperatures, predictions)
plt.xlabel('Температура (°C)')
plt.ylabel('Энергопотребление (кВт·ч)')
plt.title('Влияние температуры на энергопотребление')
plt.show()
```

---

10. Заключение

Данный проект демонстрирует основные этапы работы с машинным обучением:

✓ Подготовка и обработка данных
✓ Разделение на обучающую и тестовую выборки
✓ Обучение моделей
✓ Оценка качества моделей
✓ Визуализация результатов
✓ Практическое применение для прогнозирования

Проект может служить основой для более сложных приложений в энергетике и управлении ресурсами.

ДОПОЛНЕНИЕ К ТЕХНИЧЕСКОЙ ДОКУМЕНТАЦИИ

Проект: прогнозирование энергопотребления и стоимости электричества

Это дополнение расширяет исходную документацию: содержит небольшие изменения кода, математические формулы в LaTeX-подобной записи и простые объяснения для презентации проекта школьникам. Основная программа и использование искусственных данных сохраняются.

11. Небольшие улучшения кода

11.1. Повторяемость искусственных данных

В начало программы, после импорта библиотек, добавляется фиксирование генератора случайных чисел. Это позволяет при одинаковом коде получать одинаковые случайные данные при повторных запусках.

```
np.random.seed(42)
```

Важно: после добавления или перемещения генераций случайных чисел значения могут отличаться от результатов предыдущих запусков. Фиксация seed делает последующие запуски воспроизводимыми при неизменном порядке операций.

11.2. Понятный вывод метрик

```
print("Прогноз энергопотребления (искусственные данные):")
print(f"Средняя абсолютная ошибка (MAE): {mae_energy:.2f} кВт·ч")
print(f"Корень из средней квадратичной ошибки (RMSE): {rmse_energy:.2f} кВт·ч")

print("\\nПрогноз цены электроэнергии (искусственные данные):")
print(f"Средняя абсолютная ошибка (MAE): {mae_price:.2f} руб/кВт·ч")
print(f"Корень из средней квадратичной ошибки (RMSE): {rmse_price:.2f} руб/кВт·ч")
```

Формат :.2f выводит число с двумя знаками после запятой. Подписи указывают, что именно измеряется и в каких единицах.

11.3. Обучение модели с комментариями

```
# Создаём модель линейной регрессии
energy_model = LinearRegression()

# Обучаем модель на тренировочных данных
energy_model.fit(X_train_e, y_train_e)

# Получаем прогноз для тестовых данных
# Модель не использовала эти примеры при обучении
y_pred_energy = energy_model.predict(X_test_e)
```

11.4. Экономический расчёт

```
# Прогноз энергопотребления и цены
df['predicted_energy'] = energy_model.predict(X_energy)
df['predicted_price'] = price_model.predict(X_price)

# Расчёт предполагаемых расходов
df['predicted_cost'] = (
    df['predicted_energy'] * df['predicted_price']
)
```

12. Математическая основа и термины простыми словами

12.1. Линейная регрессия

Линейная регрессия — метод машинного обучения, который подбирает математическую зависимость по примерам и использует её для прогноза числового значения. В простом случае с одним признаком зависимость можно представить прямой линией:

$$\hat{y} = a\,x + b$$

Здесь x — входной параметр, $\hat{y}$ — прогноз, a — коэффициент наклона, b — свободный член. В данном проекте используется несколько признаков, поэтому формула имеет вид:

$$\hat{y} = w_0 + w_1 \cdot \text{temperature} + w_2 \cdot \text{day_of_week} + w_3 \cdot \text{month}$$

Коэффициенты w_0, w_1, w_2 и w_3 модель находит во время обучения. Формула применяется отдельно для энергопотребления и для цены: у каждой модели свои коэффициенты.

12.2. Разделение данных

Тренировочная выборка — часть данных, на которой модель учится. Тестовая выборка — отдельная часть, на которой проверяют прогнозы на примерах, не использованных при обучении. В проекте test_size=0.2 означает 20% тестовых данных и 80% тренировочных.

12.3. Метрики качества

MAE — средняя абсолютная ошибка. Сначала находится разница между реальным значением y_i и прогнозом $\hat{y}_i$, затем берётся модуль, чтобы знак ошибки не имел значения, и вычисляется среднее:

$$MAE = (1/n) \cdot \Sigma\, |y_i - \hat{y}_i|$$

RMSE — корень из среднего квадрата ошибок. Квадрат делает большие ошибки более заметными:

$$RMSE = \sqrt{[(1/n) \cdot \Sigma\, (y_i - \hat{y}_i)^2]}$$

Простая аналогия: MAE показывает типичный размер ошибки, а RMSE сильнее реагирует на отдельные большие промахи. Чем меньше эти показатели, тем лучше — если сравнивать одну и ту же задачу и одинаковые единицы измерения.

12.4. Другие термины

Термин	Простое объяснение
Признаки (X)	Входные параметры, по которым модель делает прогноз: температура, день недели и месяц.
Целевая переменная (y)	Значение, которое нужно предсказать: энергопотребление или цена.
Прогноз	Значение, рассчитанное обученной моделью.
Искусственные данные	Данные, созданные программой, а не полученные из реальных измерений.
Гистограмма ошибок	Столбики показывают, какие ошибки встречаются чаще.
KDE	Сглаженная кривая поверх гистограммы, показывающая общую форму распределения ошибо

13. Графики и интерпретация результатов

13.1. Реальные значения и прогноз

Точечный график сопоставляет реальные значения по горизонтальной оси с предсказанными по вертикальной. Диагональная линия означает идеальный случай: прогноз равен реальному значению. Чем ближе точки к линии, тем меньше отклонения.

13.2. Распределение ошибок

Ошибка рассчитывается как реальное значение минус прогноз: $e_i = y_i - \hat{y}_i$. Положительная ошибка означает, что прогноз ниже реального значения; отрицательная — что прогноз выше реального. Столбики показывают частоту ошибок, а KDE — сглаженную форму распределения.

13.3. Результаты одного запуска

Показатель	Результат	Интерпретация
Энергопотребление: MAE	76,07 кВт·ч	Средняя абсолютная ошибка на тестовой выборке.
Энергопотребление: RMSE	87,22 кВт·ч	Большие ошибки сильнее влияют на этот показатель.
Цена: MAE	0,22 руб/кВт·ч	Средняя абсолютная ошибка цены на тестовой выборке.
Цена: RMSE	0,28 руб/кВт·ч	Показатель ошибки, чувствительный к большим отклонениям.

Важно: значения метрик зависят от сгенерированных данных и способа их разделения. После изменения seed или генерации данных они могут измениться. Поскольку данные искусственные, метрики показывают поведение модели на демонстрационном наборе, а не подтверждённую точность для реальных тарифов и потребления.

13.4. Итоговая таблица расходов

Программа вычисляет предполагаемые расходы как произведение прогноза энергопотребления на прогноз цены:

$$\textbf{predicted_cost} = \textbf{predicted_energy} \times \textbf{predicted_price}$$

```
df['predicted_energy'] = energy_model.predict(X_energy)
df['predicted_price'] = price_model.predict(X_price)
df['predicted_cost'] = (
    df['predicted_energy'] * df['predicted_price']
)
```

Например, 338,43 кВт·ч × 4,86 руб/кВт·ч ≈ 1643,64 руб. Значения являются расчётными и основаны на прогнозах модели. Таблица строится для всех 100 строк, включая строки, использованные при обучении, поэтому её нельзя трактовать как отдельную проверку прогноза на будущие даты.

14. Краткое объяснение проекта для выступления

«Я создал две модели линейной регрессии. Первая прогнозирует энергопотребление, вторая — цену электроэнергии. Я проверяю результаты на тестовой выборке с помощью MAE и RMSE, рассматриваю графики прогнозов и ошибок, а затем перемножаю прогнозируемые энергопотребление и цену, чтобы получить предполагаемые расходы. Все данные искусственные: проект демонстрирует принцип работы машинного обучения. Для практического использования нужно обучить и проверить модель на реальных данных».

Примечание по формулам: математические выражения приведены в читаемой записи, совместимой по смыслу с LaTeX. При переносе в редактор LaTeX их можно записать, например, как \(\hat{y}=w_0+w_1x_1+w_2x_2+w_3x_3\).